

---

# Posudok vedúceho záverečnej práce

## Študijný program: Informačné systémy/Spracovanie dát

Meno študenta: **František Kajánek** , 5ZZS25      druh práce: **diplomová**

Názov práce: **Paralelná implementácia extraktora príznakov vhodného pre detekciu objektov pomocou Adaboostu**

Meno vedúceho, pracovisko: **Ing. Peter Tarábek, PhD. - KMMOA**

### 1. Náročnosť zadania na:

	malá	stredná	veľká
Teoretické znalosti		x	
Invenčnosť, tvorivosť		x	
Zber, spracovanie, vyhodnotenie dát		x	
Experimentálna činnosť		x	
Technické práce, vrátane rutinných programátorských prác			x
Návrh algoritmov, dátových štruktúr, sofistikované programovanie			x
Informačno - rešeršný prieskum a syntézu		x	

### 2. Bodové hodnotenie práce:

	max.bodov	pridelené
Hĺbka vykonanej analýzy vo vzťahu k téme	8	7
Adekvátnosť použitých metód a tvorivosť prístupu	14	13
Splnenie cieľov zadania	16	12
Kvalita riešenia	16	14
Zdôvodnenie, overenie a vyhodnotenie riešenia	14	9
Logická stavba, nadväznosť, úplnosť a zrozumiteľnosť záverečnej práce	8	7
Formálna, gramatická a stylistická úroveň záverečnej práce, dokumentácie a prezentácie výsledkov	8	6
Priebeh riešenia (organizácia práce), dodržanie časového harmonogramu, spolupráca s vedúcim DP, samostatnosť, iniciatíva, práca s informačnými zdrojmi)	16	12
Spolu	100	80

### 3. Slovné hodnotenie:

- (a) Ktoré výsledky práce predstavujú podľa vás najväčší prínos a potvrdenie inžinierskych respektíve bakalárskych schopností autora?

Diplomant porovnal a vybral implementáciu Adaboostu, ktorá je vhodná pre rozšírenie o nový extraktor obrazových príznakov. Pri výbere podrobnejšie skúmal 3 možnosti: MultiBoost, OpenCV

---

3.0 a OpenCV 2.0 implementáciu Adaboostu. Na základe skúmania mu vyšla najlepšie OpenCV 2.0 implementácia, ktorá poskytuje najlepšie možnosti pre detekciu objektov. Tento výber považujem za správny. Je potrebné poznamenať, že proces výberu nebol triviálny, nakoľko bolo jednotlivé možnosti potrebné skúmať nie len na základe funkcionalít, ktoré poskytujú, ale aj na základe toho, ako sú implementované a aké dovoľujú rozširovanie. Výsledná implementácia bola následne skúmaná do hĺbky, aby sa zabezpečilo jej správne pochopenie a napojenie vlastného deskriptora. Popri tomto procese si diplomant naimplementoval aj vlastné verzie niektorých dôležitých komponentov, ako je multi-scale detect a výpočet HAARových vlniek, čo mu umožnilo hlbšie pochopenie danej problematiky. Následne sa zamerlal na výber vhodného deskriptora pre detekciu objektov založenej na AdaBoost prístupe. Študoval hlavne aproximácie, v praxi často používaného, HOG deskriptora. Pre svoju prácu si vybral SHOG deskriptor, ktorý popísal, naimplementoval a prepojoval s AdaBoostom. Počas riešenia práce sa diplomantovi podarilo aj zefektívniť rýchlosť tréningovania AdaBoostu jeho prepojením s multi-scale detektorom pre generovanie negatívnych vzoriek.

- (b) Prípadné zdôvodnenie bodového hodnotenia, pripomienky, problémy a otázky, ku ktorým sa treba vyjadriť pri obhajobe:

Hlavným nedostatkom práce je, že sa diplomantovi nepodarilo si rozvrhnúť prácu tak, aby stihol GPU implementáciu SHOG deskriptora. Vo výsledku tak existuje len CPU implementácia. Na jednej strane tým nie je splnený jeden z cieľov práce (GPU implementácia a jej porovnanie s CPU implementáciou). Na druhej strane však skúmal existujúcu GPU implementáciu HAAR vlniek v kombinácii s multi-scale detect a Viola-Jones kaskádov, čo sú pre prácu kľúčové mechanizmy. V práci však popísal tieto poznatky len veľmi stručne. Druhou slabšou stránkou práce je overenie a vyhodnotenie riešenia. Pri testoch rýchlosti chýbajú presné údaje o tréningových parametroch, dosiahnutých výsledkoch a vlastnostiach výsledných modelov. Pri teste kvality chýbajú údaje o rýchlosti (tréning a test mód), ako aj informácie o tréningových parametroch a vlastnostiach výsledných modelov. Na základe uvedených informácií je veľmi ťažké vyvodiť jednoznačné závery.

Otázky:

1. Na str. 47 píšete: "V práci SHOG a FDA-HOG deskriptorov, Overett-Petersson sa snažili nájsť alternatívu k LiteHOG+ deskriptoru. V tejto práci sa výhradne zaoberajú nájdením deskriptora, ktorý by bol použiteľný na konci kaskády, kde treba robiť detailné rozhodnutia." Následne na str. 51 píšete: "Dôvod prečo nastal tento stav je, že výpočet SHOGu vyžaduje v každom kroku kaskády väčší počet slabých klasifikátorov. To spôsobuje viac vyhodnocovania počas detekčného kroku, aj keď je potrebné omnoho menej výpočtov v tomto kroku oproti Haarovým vlnkám."

Na prvý pohľad to vyzerá ako keby bol SHOG pomerne slabý deskriptor, keďže je potrebné v jednotlivých krokoch kaskády použiť väčší počet slabých klasifikátorov. Môžete teda presnejšie uviesť v čom má spočívať jeho schopnosť byť použiteľný na konci kaskády a či sa táto schopnosť prejavila pri testovaní, napr. pri porovnaní s HAARovými vlnkami?

2. Mohli by ste uviesť bližšie detaily (spomínané v posudku vyššie) vykonaných experimentov?

**Hodnotenie známku: B - veľmi dobre**

---

**Dňa: 05.05.2017**

podpis vedúceho záverečnej práce: